RELATÓRIO TÉCNICO E ACADÊMICO

Projeto STRESS_SCAN

Aprendizagem de Máquina: Pré-processamento, Seleção de Modelos e Validação Quantitativa

FATEC Franca · Desenvolvimento de Software Multiplataforma · PI 2026

Objetivo: Classificação do nível de estresse em três categorias (baixo, médio e alto)

Base analisada: 1.100 registros (21 atributos originais / 18 na versão reduzida)

Modelo selecionado: Regressão Logística com StandardScaler em Pipeline (modelo_estresse_LR.joblib)

Estratégia de avaliação: Divisão estratificada 80/20 e validação cruzada estratificada de 10 dobras

1. Visão Geral

O STRESS_SCAN é um aplicativo acadêmico (Flutter, API em FastAPI na Azure e MongoDB Atlas) que classifica, de forma experimental, o nível de estresse de estudantes universitários a partir de 17 perguntas. Este relatório documenta a parte de aprendizagem de máquina. O atributo-alvo, `stress_level`, tem três classes: 0 (baixo), 1 (médio) e 2 (alto). Os dados vêm do conjunto público Student Stress Monitoring Datasets (Kaggle), com 1.100 registros e 21 colunas (20 preditores e o alvo). Foi criada uma versão reduzida, com 17 preditores, e o modelo final é uma Regressão Logística (LR) com 90,45% de acurácia no teste.

2. Dados e Pré-processamento

Os notebooks verificaram a base original e a reduzida e não encontraram valores ausentes, linhas duplicadas nem registros com as mesmas respostas e classes diferentes. As classes estão equilibradas (373 baixo, 358 médio e 369 alto), o que torna a acurácia uma métrica adequada. A correlação de Spearman mostrou que todos os 17 preditores mantidos têm forte associação com o alvo (0,64 a 0,78 em valor absoluto) e também se correlacionam entre si (mediana de 0,63 entre os 136 pares). Os possíveis outliers foram sinalizados por boxplots e pela regra de 1,5 × IQR e mantidos, pois o notebook não os exclui. Como as variáveis têm escalas diferentes, aplicou-se `StandardScaler` aos algoritmos sensíveis à escala.

3. Atributos Removidos

Atributo	Motivo da exclusão	Spearman com o alvo
`blood_pressure`	Exige aferição ou conhecimento da pressão arterial.	0,444
`breathing_problem`	Pode envolver condições clínicas e ter diferentes causas, por se tratar de questão médica que exige avaliação mais criteriosa.	0,590
`mental_health_history`	Envolve informações sensíveis sobre antecedentes de saúde mental (dado pessoal sensível pela LGPD, art. 5º, II).	0,649

Os atributos foram excluídos devido a limitações metodológicas e de aplicabilidade no questionário proposto, considerando a necessidade de informações sensíveis, possíveis avaliações clínicas e dificuldades de mensuração. **A exclusão não implica irrelevância estatística:** ela representa uma decisão metodológica voltada à viabilidade da coleta de dados e à acessibilidade do aplicativo.

Para medir o custo da redução, os seis algoritmos foram avaliados nas duas bases com o mesmo protocolo. A acurácia na validação cruzada variou entre −1,36 e +0,11 p.p., e no teste entre −3,64 e +1,82 p.p. A LR teve −0,68 p.p. na validação cruzada (de 88,18% para 87,50%) e +0,91 p.p. no teste (de 89,55% para 90,45%). A versão reduzida manteve, portanto, desempenho próximo ao da original.

4. Treinamento e Resultados

A divisão foi estratificada, com 80% para treino (880 registros) e 20% para validação (220), usando `random_state=7`. Seis algoritmos (LR, SVM, LDA, Naive Bayes, KNN e árvore CART) foram comparados por validação cruzada estratificada de 10 dobras no treino e, depois, avaliados no conjunto de 220 registros. Com o `StandardScaler` dentro do pipeline, ele é ajustado somente com os dados de treino de cada dobra, o que evita vazamento de informação.

Tabela 1 – Desempenho dos algoritmos na base reduzida

Modelo	CV 10-fold (± DP)	Treino	Teste	Recall classe alta
Regressão Logística (LR)	87,50% ± 4,66	88,86%	90,45%	94,59%
Support Vector Machine (SVM)	87,50% ± 4,40	98,75%	89,55%	90,54%
Análise Discriminante Linear (LDA)	87,39% ± 3,15	87,50%	89,55%	93,24%
Naive Bayes Gaussiano (NB)	86,82% ± 3,88	88,30%	91,36%	94,59%
K-Nearest Neighbors (KNN)	86,14% ± 3,51	88,18%	88,18%	86,49%
Árvore de Decisão (CART) (CART)	86,02% ± 2,54	100,00%	87,73%	87,84%

Na validação cruzada, LR e SVM empataram em primeiro (87,50%), mas a diferença para o último colocado é de só 1,48 p.p., menor que o desvio entre dobras (2,5 a 4,7 p.p.). No teste, o Naive Bayes obteve 91,36% e a LR 90,45%, diferença de apenas 2 registros em 220, que não permite apontar um algoritmo superior. A CART (100% no treino e 87,73% no teste) e o SVM (98,75% e 89,55%) apresentaram sobreajuste, enquanto LR, NB, LDA e KNN tiveram acurácia no teste igual ou superior à do treino.

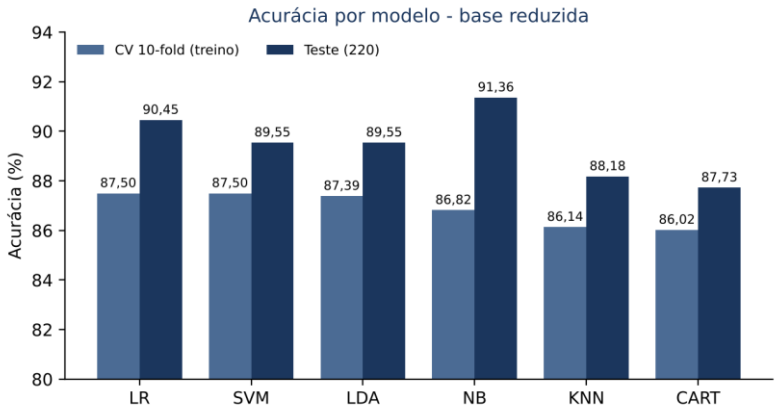


Figura 1 – Acurácia na validação cruzada e no conjunto de teste (base reduzida)

5. Justificativa para a Seleção da Regressão Logística

A Regressão Logística (LR) foi selecionada por apresentar desempenho competitivo, com 90,45% de acurácia no teste e 87,50% na validação cruzada, superando ligeiramente o Naive Bayes (86,82%) nesta última avaliação. Embora o NB tenha obtido acurácia superior no teste (91,36%), ambos alcançaram recall de 94,59% na identificação da classe de estresse alto (classe 2).

A escolha da LR também considerou as correlações identificadas entre os atributos. O algoritmo não exige a hipótese de independência condicional utilizada pelo Naive Bayes, e permite maior interpretabilidade por meio da análise de seus coeficientes. Assim, a LR foi considerada adequada à proposta de classificação dos níveis de estresse do aplicativo.

Dados que reforçam a decisão: a LR também teve a maior acurácia na validação cruzada da base original (88,18%); errou 4 dos 74 casos de estresse alto, o erro de maior custo para um aplicativo de apoio; e acertou 199 dos 220 registros do teste (Figura 2). O modelo serializado ocupa cerca de 3 KB, o que simplifica a integração à API.

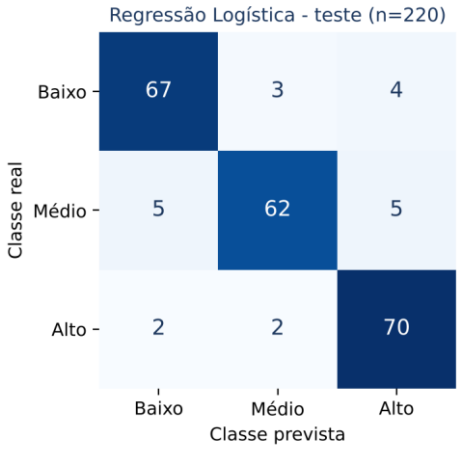


Figura 2 – Matriz de confusão da Regressão Logística no conjunto de teste

6. Artefato de Produção

O arquivo `modelo_estresse_LR.joblib` contém o pipeline treinado (`StandardScaler` e `LogisticRegression`) e a lista ordenada dos 17 atributos. A API (`POST /prever`) valida os 17 campos e suas faixas, monta a entrada na ordem correta e devolve a classe e a mensagem de que a classificação é experimental. O aplicativo deve enviar os valores brutos, sem normalização prévia, para não haver padronização em duplicidade. O modelo foi salvo com scikit-learn 1.6.1, a mesma versão fixada em `api/requirements.txt`. A cópia do repositório é idêntica à do notebook e reproduz os 90,45% no teste.

7. Limitações e Considerações Finais

- **Uso real:** as alternativas qualitativas do aplicativo são convertidas em números por uma adaptação experimental ainda não validada com usuários reais, portanto as métricas não representam necessariamente o desempenho do questionário em uso.

- **Representatividade:** o conjunto de dados não tem variável de raça/cor, e o modelo não foi validado especificamente para estudantes pretos e pardos.
- **Avaliação:** os resultados dependem de uma única divisão com 220 registros, sem base externa, e diferenças de 1 ou 2 p.p. entre modelos não são conclusivas.

A redução de 20 para 17 atributos atendeu à minimização de dados sensíveis (LGPD) e à usabilidade, sem perda crítica de desempenho. A LR foi escolhida pelo equilíbrio entre desempenho, adequação à correlação entre atributos, interpretabilidade e simplicidade de implantação.

Aviso ético e legal: por se tratar de um sistema relacionado à saúde mental e ao estresse, a aplicação deve exibir de forma ostensiva que os resultados são estimativas estatísticas de apoio informativo e não constituem diagnóstico clínico ou parecer médico.

8. Rastreabilidade dos Arquivos

Bases: `StressLevelDataset.csv` e `StressLevelDataset_reduzido.csv`. Notebooks: `Pre_processamento_reduzido.ipynb` e `Extração_Padrão_reduzido.ipynb` (histórico em `ARQUIVO`). Modelo: `modelo_estresse_LR.joblib`. API: `api/main.py` no repositório PI5_2026-2-STRESS_SCAN.